

UNIVERSITATEA TEHNICĂ „Gheorghe Asachi” din IAȘI

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE

DOMENIUL: Calculatoare și tehnologia informației

SPECIALIZAREA: Calculatoare

# Tema de casă

## MapReduce

Ciubuc Remus-Mihail

Grupa 1407 A

# Cuprins

<i>Enunțul temei de casă:</i> .....	3
<i>Noțiuni introductive</i> .....	4
<i>Etapele paradigmei MapReduce:</i> .....	5
<i>Avantajele algoritmului MapReduce:</i> .....	6
<i>Pseudocodul algoritmului MapReduce:</i> .....	7
<i>Bibliografie:</i> .....	8

## Enunțul temei de casă:

În cadrul oricărui sistem de regăsire a informațiilor, colecția de date țintă este re-organizată (sau re-modelată) pentru a optimiza funcția de căutare. Un exemplu în acest sens este dat chiar de motoarele de căutare a informațiilor pe Web: colecția de documente este stocată sub forma unui **index invers**.

Pașii implicați în construirea unui astfel de index invers sunt următorii:

1. fiecare document din cadrul colecției țintă (identificat printr-un docID) va fi parsat și spart în cuvinte unice (sau termeni unici); se obține în finalul acestui pas o lista de forma  $\langle \text{docIDx}, \{\text{term1} : \text{count1}, \text{term2} : \text{count2}, \dots, \text{termn} : \text{countn}\} \rangle$  (**index direct** – countk înseamna numărul de apariții al termenului k);
2. fiecare lista obținută în pasul anterior este spartă în perechi de forma:  $\langle \text{docIDx}, \{\text{termk} : \text{countk}\} \rangle$ ; pentru fiecare astfel de pereche, se realizează o inversare de valori astfel încât să obținem:  $\langle \text{termk}, \{\text{docIDx} : \text{countk}\} \rangle$ ;
3. perechile obținute în pasul anterior sunt sortate după termk (cheie primară), docIDx (cheie secundară);
4. pentru fiecare termk se reunesc  $\langle \text{termk}, \{\text{docIDx} : \text{countk}\} \rangle$ , astfel încât să obținem:  $\langle \text{termk}, \{\text{docIDk1} : \text{countk1}, \text{docIDk2} : \text{countk2}, \dots, \text{docIDkm} : \text{countkm}\} \rangle$  (indexul invers).

**Tema de casă** constă în implemenatarea unei soluții MPI de tip **MapReduce** pentru problema construirii unui index invers pentru o colecție de documente text.

Aplicația de test va primi ca **parametrii de intrare** numele unui director ce conține fișiere text (cu extensia ".txt") și un **nume de director pentru stocarea datelor de ieșire** și va genera pe post de răspuns un set de fișiere text ce conțin **indexul invers** corespunzător colecției de documente de intrare.

## Noțiuni introductive:

MapReduce este o paradigmă de programare aplicată la scară largă, pentru procesarea și generarea unor seturi mari de date, folosind un algoritm paralel și distribuit, pe un cluster Hadoop.

În general, se consideră că acest model implică existența unui nod de procesare cu rol de coordonator (sau master sau inițiator) și mai multe noduri de procesare cu rol de worker. Ideea principală din spatele MapReduce este maparea setului de date într-o colecție de perechi <cheie, valoare> și apoi reducerea perechilor cu aceeași cheie.

## Etapele paradigmei MapReduce:

Termenul MapReduce se referă la două sarcini separate și distincte pe care le efectuează programele Hadoop.

Un program MapReduce este compus dintr-o procedură *Map()* care efectuează filtrarea și sortarea (cum e sortarea elevilor după prenume în cozi, o coada pentru fiecare) și o metodă *Reduce()* care efectuează însumarea rezultatelor.

1. Etapa de **Mapare** –preia un set de date și îl convertește într-un alt set de date, unde elementele individuale sunt „sparte” în tuple (adică perechi cheie / valoare).
  - nodul cu rol de coordonator împarte problema „originală” în sub probleme și le distribuie către workeri pentru procesare.
  - trebuie reținut faptul că această divizare a problemei de lucru (a datelor de procesat) se realizează într-o manieră similară *divide-et-impera* –în unele cazuri nodurile worker pot divide la rândul lor sub-problema primită și pot trimite aceste subdiviziuni către alți ; rezultă, în acest caz o *arhitectură arborescentă*;
  - divizarea caracteristică acestei etape nu trebuie să coreleze efectiv dimensiunea datelor de intrare cu numărul de workeri din sistem; un worker poate primi mai multe sub-probleme de rezolvat;
2. Etapa de **reducere** –preia ieșirea de la etapa de mapare ca fiind datele de intrare și combină aceste tuple, rezultând un alt set de tuple, dar de dimensiuni mai mici.
  - nodul cu rol de coordonator (sau un set de noduri cu rol de woker „desemnat” de coordonator) colectează soluțiile sub-problemelor și le combină pentru a obține rezultatul final al procesării dorite.

Sistemul **MapReduce** administrează serverele distribuite, rulând diferite sarcini în paralel, gestionează comunicațiile și transferul de date între diferitele componente ale sistemului, precum și asigurarea redundanței și a toleranței erorilor.

Schematic, cele două etape sunt prezentate în figura 1.[5]

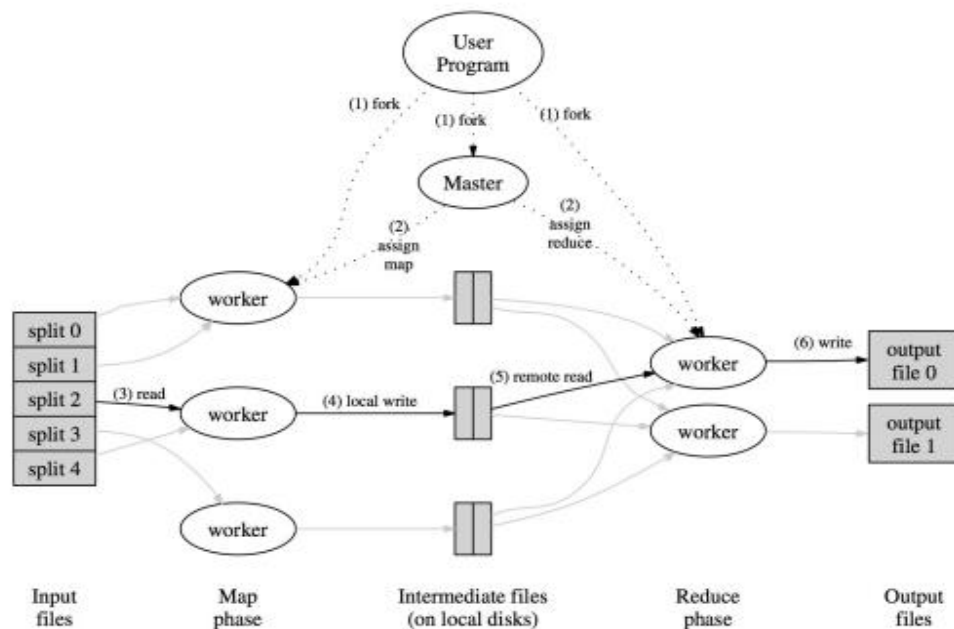


Figura 1: Paradigma MapReduce[5]

**Michael Kleber** (Google Inc.) descrie următoarele etapele implicate în paradigma MapReduce:

### 1. Preprocesare:

Datele sunt pregătite pentru etapa de mapare. Dimensiunea lor se alege astfel încât procesul să fie eficient ( vor fi distribuite în mod egal, pentru ca numărul acestora să nu fie prea mare ). Diviziunile vor fi asignate în mod continuu. În cazul în care o mașină se va defecta, diviziunea acesteia se va asigna unei alteia. [1][2]

### 2. Mapare:

În această etapă are loc stabilirea datelor de interes.

Etapa de mapare constă în maparea diviziunilor datelor de intrare în perechi cheie-valoare. O pereche cheie-valoare are forma „(termID, docID)”. [1][2]

### 3. Amestecare și sortare:

Datele vor fi organizate astfel încât să fie optimizată etapa de reducere.[1][2]

### 4. Reducere:

În această etapă, valorile obținute din etapa anterioară sunt combinate și returnate ca o singură ieșire. Reducerea poate returna zero sau mai multe perechi cheie-valoare.[1][2]

### 5. Stocare rezultat

## Avantajele algoritmului MapReduce:

Cel mai mare avantaj al algoritmului MapReduce este reprezentat de ușurința scalării procesărilor de date peste mai multe noduri computaționale. Odată ce scriem o aplicație în forma MapReduce scalarea acelei aplicații pentru a se putea executa peste sute, mii, sau chiar zeci de mii de mașini într-un cluster reprezintă doar o chestiune de modificarea unei configurații. De asemenea, MapReduce oferă flexibilitate în procesarea structurii sau a datelor nestructurate de către diverse companii care pot folosi datele și pot opera pe diferite tipuri de date.

MapReduce are o toleranță mare la defecte. Ca un sistem de tip MapReduce să pice, trebuie să „pice” toți workerii la o anumită fază a algoritmului. În momentul în care un worker pică, task-ul asignat acelui worker, este asignat altui worker.

## Pseudocodul algoritmului MapReduce:[2]

```
function map(String name, String document):  
    // name: document name  
    // document: document contents  
    for each word w in document:  
        emit (w, 1)  
  
function reduce(String word, Iterator partialCounts):  
    // word: a word  
    // partialCounts: a list of aggregated partial counts  
    sum = 0  
    for each pc in partialCounts:  
        sum += pc  
    emit (word, sum)
```

## Exemple:

Putem observa cele două etape ( Map și Reduce ) precum și modul de funcționare al paradigmei MapReduce în cele două figuri de mai jos:

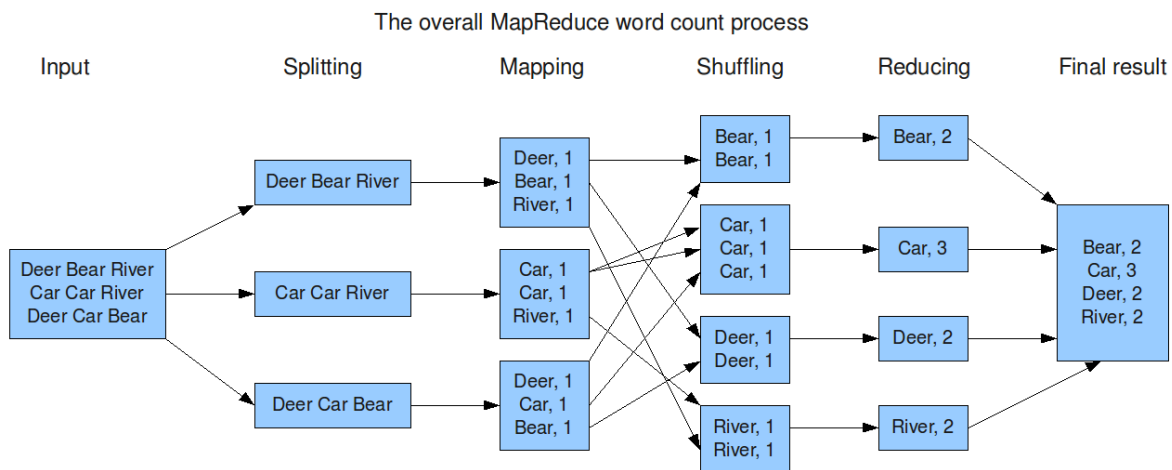


Figura 2[4]




Figura 3[4]

## **Bibliografie:**

- [1].Michael Kleber. The MapReduce paradigm.  
<https://sites.google.com/site/mriap2008/lectures>, January 2008.
- [2].Wikipedia. MapReduce. <http://en.wikipedia.org/wiki/MapReduce>, November 2013.
- [3].Laborator ALPD
- [4]. <https://www.todaysoftmag.com/article/1358/hadoop-mapreduce-deep-diving-and-tuning>